

Aluno: Rafael Holder de Oliveira

GitHub: <https://github.com/rafaelholder/CESAR-2026.2-ia-ciberseguranca>.

1. Valores infinitos

Flow Bytes/s e Flow Packets/s são taxas divididas pela duração do fluxo; com duração zero ou quase zero, a divisão estoura para infinito. Não dá para mantê-los porque o scikit-learn recusa a entrada e qualquer média ou padronização vira inf/NaN. Substituí pelo maior valor finito (2,07 bilhões de bytes/s), preservando o registro.

2. Duplicatas e ausentes

Encontrei 308.381 duplicatas (10,9% da base). Cópias do mesmo ataque fazem o modelo decorar aquele padrão e, se caem no treino e no teste, inflam a métrica (vazamento). Descartar NaN exige cuidado porque pode apagar ataques raros; no meu caso, o dropna tirou só 353 linhas, pois a maioria dos NaN já estava em duplicatas.

3. Desbalanceamento (EDA)

83,1% dos fluxos são BENIGN, então um modelo que chama tudo de benigno acerta 83% sem detectar nenhum ataque. Alguns ataques são raríssimos: na amostra, Heartbleed teve 1 exemplo e Sql Injection 2. O gráfico "Benigno vs. Ataque" e o value_counts() revelam isso antes do treino.

4. Normalização

O K-Means usa distância euclidiana: Flow Bytes/s chega a 2,07 bilhões e SYN Flag Count vai só de 0 a 1, então a feature de maior escala domina a distância e define os grupos. Padronizar coloca todas na mesma régua. O Random Forest não sofre com isso porque cada divisão compara uma única feature com um limiar, e mudar a escala não muda a ordem dos valores.

5. Comparar uma feature

No boxplot de Total Fwd Packets, o PortScan quase sempre tem 1 pacote por fluxo, enquanto o benigno fica entre 2 e 4, então a feature separa bem esse ataque. Já DDoS e BENIGN se sobrepõem, o que mostra que ela sozinha não basta e precisa ser combinada com outras.